


INTRODUCTION ET PROBLÉMATIQUE

Les séismes constituent l'une des catastrophes naturelles les plus destructrices et les plus difficiles à anticiper. Face à l'augmentation des données sismiques disponibles, il devient essentiel de développer des outils capables d'analyser et de prévoir l'activité sismique. Ce projet vise à répondre à cette problématique en proposant une plateforme intelligente permettant de classer les séismes et de prédire l'activité sismique future, aussi bien à l'échelle globale que par zone géographique, à partir de données historiques et temps réel.




DATASET SECTION

- **Source:** USGS Earthquake Catalog API
- **Period:** 2015 – 2026
- **Events:** 173,501
- **Features:** 27
- **Magnitude range:** 4.0 – 8.8

#	id	time	updated	time	longitude	latitude	depth	mag	magType	mt	sl	alert	tsunami	sig	status	type
0	us0000000	2020-01-05 00:01:05	2020-01-05 00:01:05	126.8024	7.9301	33.00	40 km NE of Kaniwhang, Philippines	4.6	mb	2.0	...	None	0	326	reviewed	earthquake
1	us0000001	2020-01-05 00:01:07	2020-01-05 00:01:07	15.4546	38.5660	296.62	18 km SSE of Marina di Camerota, Italy	4.1	mb	3.0	...	None	0	219	reviewed	earthquake
2	aka202000000	2020-01-05 00:01:07	2020-01-05 00:01:07	133.0290	60.2040	141.80	74 km NE of Port of Spain, Alaska	5.3	ml	210.0	...	None	0	188	reviewed	earthquake
3	aka202000001	2020-01-05 00:01:07	2020-01-05 00:01:07	140.7790	61.4940	28.10	4 km NW of Port of Spain, Alaska	2.9	ml	40.0	...	None	0	129	automatic	earthquake
4	aka202000002	2020-01-05 00:01:07	2020-01-05 00:01:07	130.8770	61.5240	57.80	19 km NE of Port of Spain, Alaska	2.5	ml	50.0	...	None	0	96	automatic	earthquake

PREPROCESSING PIPELINE



MODÈLE 2 : PRÉVISION SISMIQUE GLOBALE

Objectif


Prédire le nombre de séismes attendus au cours de la semaine suivante à partir des données sismiques historiques.

Méthodologie

Les données ont été agrégées à l'échelle hebdomadaire afin de construire une série temporelle. Plusieurs variables explicatives ont été générées, notamment les retards temporels (Lag 1, Lag 2, Lag 3), les moyennes mobiles, les statistiques de magnitude, l'énergie sismique et les composantes de saisonnalité. Plusieurs modèles de régression ont été évalués et comparés.

Modèle retenu

Le modèle XGBoost Regressor a présenté les meilleures performances prédictives et a été sélectionné pour la prévision du nombre de séismes.




MODÈLE 3 : PRÉVISION PAR ZONE GÉOGRAPHIQUE

Objectif


Prédire le nombre de séismes attendus la semaine suivante pour chaque zone géographique à partir de l'historique de l'activité sismique

Méthodologie


Les coordonnées géographiques (latitude, longitude) ont été regroupées automatiquement en 10 zones sismiques à l'aide de l'algorithme K-Means. Pour chaque zone, une série temporelle hebdomadaire a été construite puis enrichie par des variables temporelles (lags et statistiques glissantes). Plusieurs modèles ont été évalués et le modèle XGBoost Regressor a été retenu pour ses meilleures performances prédictives.



ARCHITECTURE GLOBALE



Dashbord



STACK TECHNIQUE

Requests: Récupération des données via des API.
KNNImputer: Remplacement des valeurs manquantes par la méthode des plus proches voisins.
Scikit-learn: Développement et entraînement des modèles de Machine Learning.
Joblib: Sauvegarde et chargement des modèles entraînés.
Pandas: Manipulation et prétraitement des données.
Folium + Plotly: Création de cartes et de graphiques interactifs pour la visualisation des données.



MODÈLE 1 : CLASSIFICATION DES SÉISMES


Objectif

Classer les séismes en trois catégories :

- Faible
- Modéré
- Fort

Méthodologie

Après le prétraitement des données et l'extraction des caractéristiques, plusieurs algorithmes de classification ont été évalués afin d'identifier le modèle le plus performant.




MODÈLE RETENU

Le modèle Random Forest a obtenu les meilleures performances globales et a été sélectionné comme modèle final pour la classification des séismes.



PIPELINE D'AUTOMATISATION

Un pipeline automatisé a été mis en place pour assurer le traitement continu des données sismiques et la génération des prédictions. Les données sont collectées en temps réel depuis l'API USGS puis prétraitées à travers plusieurs étapes de nettoyage, d'imputation des valeurs manquantes et d'ingénierie des caractéristiques. Les données préparées alimentent ensuite trois modèles complémentaires : un modèle de classification des séismes, un modèle de prévision globale du nombre de séismes pour la semaine suivante et un modèle de prévision spatiale par zone géographique. Les résultats générés sont automatiquement sauvegardés, exposés via une API FastAPI et visualisés au sein d'un tableau de bord interactif permettant le suivi en temps réel de l'activité sismique.



RÉSUMÉ

Plateforme intelligente de surveillance et de prévision sismique basée sur des données USGS, intégrant la classification des séismes ainsi que la prédiction de leur fréquence et de leur répartition géographique. Elle repose sur un pipeline automatisé de traitement des données, exposé via une API FastAPI et visualisé à travers un tableau de bord interactif en temps réel.

PERSPECTIVES

Dans les perspectives d'évolution, le projet prévoit l'intégration d'un pipeline MLOps afin d'automatiser le réentraînement hebdomadaire des modèles à partir des nouvelles données. Ce dispositif permettra également de gérer le déploiement continu du système, assurant ainsi une mise à jour régulière des performances et une meilleure adaptation aux variations de l'activité sismique.

Scannez pour consulter nos profil LinkedIn

Consulter le projet:



Israa

Khadija

GITHUB