

ISKA_SEISMIC : Real-Time Earthquake Classification and Forecasting using Machine Learning

Réalisée par:

- ALDIEBES GHANEM Israa
- ZAAFA Khadija

Encadré par :

Pr. Guendoul Oumaima

Demandé par :

Pr. El Habib Benlahmar

Table des matières

Chapitre 1 : Introduction générale.....	7
1. Contexte	7
2. Problématique.....	7
3. Objectifs du projet.....	8
4. Méthodologie adoptée	8
5. Organisation du mémoire	8
Chapitre 2 : Collecte et Prétraitement des Données	10
1. Introduction	10
2. Processus global de préparation des données.....	10
3. Collecte des données	11
3.1 Source des données	11
3.2 Variables collectées.....	12
3.3 Description du jeu de données	12
Chapitre 3 : Nettoyage des données	14
1. Introduction	14
2. Traitement des valeurs manquantes	14
2.1 Analyse des valeurs manquantes.....	14
2.2 Stratégie de traitement.....	15
2.3 Vérification après traitement.....	15
3. Traitement des valeurs aberrantes	16
3.1 Détection des valeurs aberrantes	16
3.2 Filtrage des valeurs aberrantes	17
4. Nettoyage des variables catégorielles	17
4.1 Filtrage selon le statut des événements	17
4.2 Filtrage selon le type d'événement	18
5. Vérification finale du nettoyage.....	19
6. Conclusion.....	19
Chapitre 4 : Analyse Exploratoire des Données (EDA).....	20
1. Introduction	20
2 Analyse univariée	20
2.1 Évolution mensuelle du nombre de séismes	20
2.2 Évolution de la magnitude maximale.....	21

2.3 Séismes majeurs et tsunamis	21
2.4 Évolution de la magnitude maximale.....	22
3. Analyse bivariée.....	22
3.1 Relation profondeur – magnitude.....	22
3.2 Densité de profondeur selon la magnitude	23
4. Analyse spatiale.....	23
4.1 Top 15 régions sismiques.....	23
5. Analyse multivariée.....	24
5.1 Corrélations (Pearson et Spearman).....	24
5.2 Corrélations fortes	24
5.3 Corrélations faibles	24
5.4 Synthèse multivariée	25
5.5 Synthèse globale de l'EDA	25
Chapitre 5 : Préparation des données pour la modélisation	26
1. Introduction	26
2. Préparation des données pour le Modèle 1 : Classification de la magnitude.....	26
2.1 Création de la variable cible.....	26
2.2 Analyse de l'équilibre des classes.....	27
2.3 Transformation logarithmique.....	27
2.4 Détection du Data Leakage	28
2.5 Préparation des variables explicatives:	28
2.6 Découpage Train/Test	29
3. Préparation des données pour le Modèle 2 : Prévission temporelle	29
3.1 Construction de la série temporelle	29
3.2 Création des variables de retard (Lag Features).....	29
3.3 Création de variables physiques	30
3.4 Encodage des variables cycliques	31
3.5 Sélection des variables	31
3.6 Normalisation des variables	32
3.7 Découpage chronologique.....	32
Chapitre 6 : Modélisation.....	34
1. Introduction	34
2.Modèle 1 : Classification de la magnitude	34

2.1 Objectif.....	34
2.2 Algorithmes testés	34
2.3 Entraînement et évaluation croisée	34
2.4 Résultats	35
2.5 Analyse des résultats	35
2.6 Vérification de l'overfitting	35
3.Modèle 2 : Prévission temporelle (approche globale)	36
3.1 Objectif.....	36
3.2 Algorithmes testés	36
3.3 Résultats	37
3.4 Analyse des résultats	37
3.5 Visualisation des prédictions.....	38
4. Modèle 3 : Prévission spatiale (approche par zone)	38
4.1 Objectif.....	38
4.2 K-Means : Construction des zones spatiales	38
4.3 Agrégation temporelle par zone	39
4.4 Création des features temporelles par zone.....	39
4.5 Intégration du modèle 2 (prédiction globale).....	40
4.6 Résultats par zone.....	40
5. Synthèse des performances	41
Chapitre 7 : Intégration des modèles dans un dashboard interactif en temps réel	42
1. Introduction	42
2. Architecture générale du pipeline dynamique.....	42
3. Fonction dynamique de classification des séismes	43
4. Fonction dynamique de prévission temporelle	43
5. Fonction dynamique de prédiction des zones à risque	44
6. Orchestration du pipeline	44
7. Alimentation du dashboard interactif	45
8. Résultat final : Dashboard interactif.....	45
Conclusion générale	47
Perspectives	48

Liste des figures

Figure 1 Aperçu des données brutes extraites depuis l'API USGS (DataFrame initial)	11
Figure 2 : Informations générales sur le jeu de données.	13
Figure 3: Dimensions du jeu de données	13
Figure 4 : Heatmap des valeurs manquantes avant nettoyage.....	15
Figure 5 : Heatmap des valeurs manquantes après nettoyage.....	16
Figure 6 : Rapport des pourcentages de valeurs aberrantes.	17
Figure 7 : Distribution de la variable status	18
Figure 8 : Distribution des types d'événements avant filtrage.	18
Figure 9 : Nombre de séismes par mois (2021–2022)	20
Figure 10 : Magnitude maximale mensuelle	21
Figure 11 : Séismes ≥ 6.0 et occurrence de tsunamis.....	21
Figure 12 : Top 10 zones sismiques	22
Figure 13 : Scatter plot profondeur vs magnitude.....	22
Figure 14 : Densité de la profondeur par classe de magnitude	23
Figure 15 : Top 15 régions sismiques	23
Figure 16 : Matrices de corrélation	24
Figure 17 : Distribution des classes de magnitude	26
Figure 18 : Histogrammes avant/après transformation logarithmique.....	28
Figure 19 ; Top corrélations avec la magnitude	28
Figure 20 : DataFrame hebdomadaire	29
Figure 21 : Aperçu des variables lag.....	30
Figure 22 : Variables physiques	31
Figure 23 : Importance des variables (SHAP)	32
Figure 24 : Tableau comparatif des modèles (résultats)	35
Figure 25 : Diagramme de comparaison réel vs prédit (entraînement / test)	36
Figure 26 : Tableau comparatif des modèles temporels.....	37
Figure 27 : Diagramme de comparaison valeurs réelles vs prédites (XGBoost)	38
Figure 28 : Les 10 clusters	38
Figure 29 : Aperçu de l'agrégation par zone	39
Figure 30: Aperçu des features temporelles par zone	40
Figure 31 : Exemple de fonctionnement du modèle 3	40
Figure 32: Pipeline d'automatisation.....	43
Figure 33 : – Dashboard interactif de prévision sismique développé dans ce projet.	45

Liste des tableaux

Tableau 1: : Variables extraites depuis l'API USGS.....	12
Tableau 2 : Analyse des valeurs manquantes.....	14
Tableau 3 : Détection des valeurs aberrantes.....	16
Tableau 4 : Les modalités du variable statut.....	17
Tableau 5 : les modalités de variable 'type'	18
Tableau 6 : phases d'EDA	20
Tableau 7 : Corrélations fortes	24
Tableau 8 : Corrélations faibles	24
Tableau 9 : Corrélations faibles	24
Tableau 10 : Classement du magnitude.....	26
Tableau 11 : les transformations logarithmiques	27
Tableau 12 : Split du data.....	29
Tableau 13 : Les variables physiques.....	30
Tableau 14 : Les modèles proposés.....	34
Tableau 15 : Les algorithmes testés	34
Tableau 16 :Les modèles proposés pour TimeSeries	36
Tableau 17 : Tableau des performances par zone	41

Chapitre 1 : Introduction générale

1. Contexte

Les catastrophes naturelles représentent aujourd'hui l'un des principaux défis auxquels sont confrontées les sociétés modernes. Parmi elles, les séismes figurent parmi les phénomènes les plus imprévisibles et les plus destructeurs. Chaque année, plusieurs milliers de tremblements de terre sont enregistrés à travers le monde, provoquant parfois des pertes humaines importantes ainsi que des dommages matériels considérables.

Grâce au développement des réseaux de surveillance sismique et à la disponibilité de bases de données ouvertes, un volume important d'informations est désormais collecté en temps réel. Ces données offrent de nouvelles opportunités pour exploiter les techniques de l'intelligence artificielle afin d'améliorer l'analyse des événements sismiques, d'identifier les zones à risque et d'estimer leur évolution future.

Parallèlement, les progrès réalisés dans les domaines du Machine Learning, du Deep Learning et des systèmes MLOps permettent aujourd'hui de concevoir des applications intelligentes capables d'intégrer automatiquement de nouvelles données, d'actualiser leurs modèles et de fournir des prédictions en continu.

Dans ce contexte, la mise en place d'un système intelligent capable d'analyser les données sismiques en temps réel constitue une contribution importante pour l'aide à la décision et la surveillance des risques naturels.

2. Problématique

Bien que plusieurs plateformes permettent de consulter les séismes enregistrés à travers le monde, elles se limitent généralement à la visualisation des événements passés sans proposer une analyse prédictive complète.

Les principales limites observées sont notamment :

- l'absence de classification automatique du niveau de danger des séismes récents ;
- le manque de prévisions globales concernant l'évolution de l'activité sismique ;
- l'absence d'identification dynamique des zones susceptibles de présenter un risque élevé ;
- une faible automatisation de la mise à jour des modèles de prédiction.

Ces limitations montrent la nécessité de développer une plateforme capable d'intégrer plusieurs modèles d'intelligence artificielle dans un pipeline automatisé fonctionnant en temps réel.

3. Objectifs du projet

L'objectif principal de ce travail est de concevoir une plateforme intelligente de surveillance sismique capable d'exploiter les données de l'USGS afin de produire des analyses et des prédictions actualisées automatiquement.

Les objectifs spécifiques sont les suivants :

- collecter automatiquement les données sismiques depuis l'API USGS ;
- prétraiter les données afin d'assurer leur qualité ;
- développer un modèle de classification des séismes selon leur niveau de magnitude ;
- prédire le nombre de séismes attendu pour la semaine suivante à l'aide d'un modèle de séries temporelles ;
- identifier les zones géographiques présentant le plus grand risque sismique ;
- intégrer les modèles dans un pipeline automatisé reposant sur les principes du MLOps ;
- développer un dashboard interactif permettant de visualiser les résultats en temps réel.

4. Méthodologie adoptée

Pour atteindre ces objectifs, une méthodologie progressive a été suivie.

Dans un premier temps, les données sismiques ont été collectées à partir de l'API USGS. Une phase de prétraitement a ensuite permis de nettoyer les données, de traiter les valeurs manquantes, de supprimer les observations aberrantes et de construire les variables nécessaires à l'entraînement des modèles.

Plusieurs modèles d'intelligence artificielle ont ensuite été développés pour répondre aux différentes tâches du projet : classification des séismes, prévision temporelle et estimation des risques par zones géographiques.

Enfin, les modèles retenus ont été intégrés dans une architecture MLOps permettant leur exécution automatique, leur comparaison, leur mise à jour et leur déploiement au sein d'un dashboard interactif affichant les résultats en temps réel.

5. Organisation du mémoire

Ce mémoire est organisé en plusieurs chapitres.

Le deuxième chapitre présente les concepts théoriques relatifs aux séismes, à l'intelligence artificielle, au Machine Learning ainsi qu'aux techniques utilisées dans ce travail.

Le troisième chapitre décrit les données utilisées ainsi que les différentes étapes du prétraitement.

Le quatrième chapitre est consacré au développement et à l'entraînement des modèles de classification.

Le cinquième chapitre présente le modèle de prévision temporelle ainsi que l'estimation des zones sismiques.

Le sixième chapitre décrit la mise en œuvre du pipeline MLOps, la gestion des versions des modèles et leur automatisation.

Le septième chapitre présente l'intégration des modèles dans un dashboard interactif fonctionnant en temps réel.

Enfin, le mémoire se termine par une conclusion générale qui résume les principaux résultats obtenus et propose plusieurs perspectives d'amélioration.

Chapitre 2 : Collecte et Prétraitement des Données

1. Introduction

Dans tout projet de science des données, la qualité des résultats obtenus dépend directement de la qualité des données utilisées pour l'entraînement des modèles. Les données brutes issues de différentes sources contiennent souvent des valeurs manquantes, des incohérences, des observations aberrantes ou encore des informations non pertinentes susceptibles d'affecter les performances des modèles d'apprentissage automatique. Une phase de prétraitement est donc indispensable afin de produire un jeu de données fiable, cohérent et adapté aux analyses ultérieures.

Dans le cadre de ce projet, l'objectif est de réaliser une analyse spatio-temporelle des événements sismiques afin de mieux comprendre les zones à risque et de développer des modèles capables d'analyser et de prédire l'activité sismique. Pour atteindre cet objectif, plusieurs étapes de préparation des données ont été réalisées, allant de la collecte des données jusqu'à leur transformation pour les différents modèles développés.

Les principales étapes de cette phase sont les suivantes :

- Collecte des données sismiques depuis l'API de l'USGS ;
- Description et organisation des variables collectées ;
- Traitement des valeurs manquantes ;
- Détection et suppression des valeurs aberrantes ;
- Nettoyage des variables catégorielles ;
- Préparation des jeux de données destinés aux différents modèles d'intelligence artificielle.

2. Processus global de préparation des données

Avant le développement des modèles de prédiction, les données ont été soumises à une chaîne complète de prétraitement visant à garantir leur qualité et leur cohérence. Chaque étape répond à un objectif précis : améliorer la qualité des informations, supprimer les données non pertinentes et produire des jeux de données adaptés aux différents modèles développés dans ce projet.

3. Collecte des données

3.1 Source des données

Les données utilisées dans cette étude proviennent de l'API publique du **United States Geological Survey (USGS)**, l'une des principales références mondiales en matière de surveillance et de diffusion des informations sismiques. Cette plateforme met à disposition des catalogues régulièrement mis à jour contenant les caractéristiques détaillées des événements sismiques enregistrés à travers le monde.

Le choix de cette source repose sur plusieurs avantages :

- disponibilité libre et gratuite des données ;
- couverture mondiale des événements sismiques ;
- mise à jour régulière des observations ;
- richesse des variables spatiales, temporelles et sismologiques ;
- fiabilité reconnue dans les travaux scientifiques.

Les données exploitées couvrent une période d'environ **dix années**, allant de **2015 à 2025**. Cette période offre un volume de données suffisamment important pour permettre l'étude des tendances spatio-temporelles ainsi que l'entraînement des modèles de prédiction développés dans ce projet.

	id	time_utc	updated_utc	longitude	latitude	depth_km	place	mag	magType	nst	...	alert	tsunami	sig	status	type
0	us6000svgp	2026-05-05 23:10:51	2026-05-06 00:01:05	126.8824	7.9301	35.00	45 km NE of Kinablangan, Philippines	4.6	mb	22.0	...	NaN	0	326	reviewed	earthquake
1	us6000svgl	2026-05-05 23:02:33	2026-05-06 01:09:37	15.4546	39.8560	298.62	18 km SSE of Marina di Camerota, Italy	4.1	mb	37.0	...	NaN	0	259	reviewed	earthquake
2	aka2026iwurap	2026-05-05 22:57:40	2026-05-06 00:57:42	-153.0290	60.3940	141.60	74 km ENE of Port Alsworth, Alaska	3.5	ml	219.0	...	NaN	0	188	reviewed	earthquake
3	aka2026iwupmw	2026-05-05 22:55:56	2026-05-06 08:20:03	-149.7790	61.4940	28.10	4 km NNW of Knik, Alaska	2.9	ml	45.0	...	NaN	0	129	automatic	earthquake
4	aka2026iwtbux	2026-05-05 22:10:10	2026-05-05 23:14:46	-150.8770	61.5240	57.90	19 km W of Susitna, Alaska	2.5	ml	56.0	...	NaN	0	96	automatic	earthquake

5 rows × 27 columns

Figure 1 Aperçu des données brutes extraites depuis l'API USGS (DataFrame initial)

3.2 Variables collectées

Chaque événement sismique est décrit par un ensemble de variables appartenant à plusieurs catégories. Ces informations permettent de caractériser les séismes selon leur localisation, leurs propriétés physiques, leur qualité de mesure ainsi que leurs éventuels impacts.

Catégorie	Variables	Description
Temporelles	time_utc, updated_utc	Date et heure de l'événement ainsi que sa dernière mise à jour.
Spatiales	latitude, longitude	Coordonnées géographiques de l'épicentre du séisme.
Sismologiques	mag, depth_km, magType	Magnitude, profondeur et méthode de calcul de la magnitude.
Qualité des mesures	gap, rms, dmin, nst	Indicateurs permettant d'évaluer la qualité et la précision des mesures enregistrées.
Impact	tsunami, alert, felt	Informations relatives aux conséquences potentielles du séisme.
Métadonnées	id, url, status	Informations d'identification et de traçabilité des événements.

Tableau 1: : Variables extraites depuis l'API USGS.

Les variables spatiales et temporelles constituent la base de l'analyse spatio-temporelle, tandis que les variables sismologiques décrivent les caractéristiques physiques de chaque événement. Les indicateurs de qualité des mesures sont utilisés afin d'évaluer la fiabilité des observations, tandis que les métadonnées assurent la traçabilité des événements enregistrés.

3.3 Description du jeu de données

Après la collecte, une première analyse descriptive a été réalisée afin d'obtenir une vue d'ensemble du jeu de données.

Le jeu de données initial comporte :

- **environ 136 000 événements sismiques** enregistrés ;
- des variables numériques, catégorielles et temporelles ;
- une couverture géographique mondiale ;
- une période d'observation d'environ dix années.

Avant toute phase de modélisation, une analyse de la qualité des données a été effectuée afin d'identifier les éventuelles anomalies susceptibles d'influencer les performances des modèles.

Cette première inspection a notamment permis d'observer :

- la présence de valeurs manquantes dans certaines variables ;

- des variables présentant un taux très élevé de données absentes ;
- quelques observations situées en dehors des intervalles physiques admissibles ;
- des événements ne correspondant pas à des séismes naturels (explosions minières, glissements de terrain, etc.).

Ces constats justifient la mise en œuvre des différentes opérations de nettoyage présentées dans les sections suivantes.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 136457 entries, 0 to 136456
Data columns (total 27 columns):
#   Column                Non-Null Count  Dtype
---  -
0   id                    136457 non-null object
1   time_utc              136457 non-null object
2   updated_utc           136457 non-null object
3   longitude              136457 non-null float64
4   latitude              136457 non-null float64
5   depth_km              136457 non-null float64
6   place                 136457 non-null object
7   mag                   136457 non-null float64
8   magType               136457 non-null object
9   nst                   108601 non-null float64
10  gap                   128422 non-null float64
11  dmin                  125343 non-null float64
12  rms                   136447 non-null float64
13  net                   136457 non-null object
14  felt                  21926 non-null float64
15  cdi                   21926 non-null float64
16  mmi                   9157 non-null float64
17  alert                 4167 non-null object
18  tsunami               136457 non-null int64
19  sig                   136457 non-null int64
20  status                136457 non-null object
21  type                  136457 non-null object
22  horizontalError        0 non-null float64
23  depthError             0 non-null float64
24  magError              0 non-null float64
25  magNst                0 non-null float64
26  url                   136457 non-null object
dtypes: float64(15), int64(2), object(10)
memory usage: 28.1+ MB
```

Figure 2 : Informations générales sur le jeu de données.

```
df.shape
```

```
(136457, 27)
```

Figure 3: Dimensions du jeu de données .

Chapitre 3 : Nettoyage des données

1. Introduction

La qualité des données constitue un facteur déterminant dans le développement de modèles d'intelligence artificielle performants. Les données brutes collectées à partir de l'API de l'USGS présentent plusieurs imperfections, notamment des valeurs manquantes, des observations aberrantes ainsi que certaines catégories d'événements ne correspondant pas à l'objectif de cette étude.

Afin d'obtenir un jeu de données fiable et cohérent, plusieurs opérations de nettoyage ont été réalisées. Ces traitements visent à préserver les informations pertinentes tout en éliminant les données susceptibles d'introduire du bruit ou des biais dans les analyses et les modèles de prédiction.

Les principales étapes de cette phase sont :

- Analyse et traitement des valeurs manquantes ;
- Détection et suppression des valeurs aberrantes ;
- Nettoyage des variables catégorielles ;
- Vérification de la qualité finale du jeu de données.

2. Traitement des valeurs manquantes

2.1 Analyse des valeurs manquantes

La première étape du nettoyage consiste à analyser la quantité de valeurs manquantes présente dans chaque variable. Pour cela, le nombre ainsi que le pourcentage de données absentes ont été calculés pour chaque colonne du jeu de données.

Cette analyse permet d'identifier les variables pouvant être conservées après imputation ainsi que celles dont le taux élevé de valeurs manquantes justifie leur suppression.

Colonne	Valeurs manquantes	Pourcentage (≈)
nst	27 507	20 %
gap	7 271	5 %
dmin	10 212	7 %
rms	10	0,01 %
felt	103 771	76 %
cdi	103 771	76 %
mmi	115 349	84 %
alert	119 884	87 %
horizontalError	123 686	90 %
depthError	123 686	90 %
magError	123 686	90 %
magNst	123 686	90 %

Tableau 2 : Analyse des valeurs manquantes.

Les résultats montrent que certaines variables présentent un faible ou moyen taux de données manquantes, tandis que d'autres dépassent largement 80 %, rendant leur exploitation peu pertinente.




Figure 4 : Heatmap des valeurs manquantes avant nettoyage.

2.2 Stratégie de traitement

Deux stratégies ont été adoptées selon le taux de valeurs manquantes et l'importance de chaque variable.

2.2.1 Imputation par K-Nearest Neighbors (KNN)

Les variables **nst**, **gap**, **dmin** et **rms** sont directement liées à la qualité des mesures sismiques. Leur suppression aurait entraîné une perte importante d'informations. Une imputation par l'algorithme **K-Nearest Neighbors (KNN)** a donc été réalisée afin d'estimer les valeurs manquantes à partir des observations les plus similaires.

2.2.2 Suppression des variables fortement incomplètes

Les variables **felt**, **cdi**, **mmi**, **alert**, **horizontalError**, **depthError**, **magError** et **magNst** présentent un taux de valeurs manquantes supérieur à 80 %. Leur conservation aurait introduit un biais important et une imputation n'aurait pas permis d'obtenir des estimations suffisamment fiables. Elles ont donc été supprimées du jeu de données.

2.3 Vérification après traitement

Après l'imputation des valeurs manquantes et la suppression des variables fortement incomplètes, une nouvelle vérification a été effectuée.

La heatmap obtenue confirme la disparition des valeurs manquantes dans les variables conservées, indiquant que le jeu de données est désormais complet et prêt pour les traitements suivants.




Figure 5 : Heatmap des valeurs manquantes après nettoyage.

3. Traitement des valeurs aberrantes

3.1 Détection des valeurs aberrantes

Contrairement aux méthodes statistiques classiques telles que l'IQR ou le Z-score, nous avons adopté une approche basée sur les connaissances du domaine (Domain Knowledge). En effet, certaines valeurs extrêmes peuvent correspondre à de véritables phénomènes sismiques et ne doivent donc pas être supprimées uniquement sur la base de leur éloignement statistique.

Les intervalles retenus correspondent aux limites physiques généralement admises en sismologie.

Variable	Intervalle physique	Outliers détectés	Pourcentage
depth_km	[0 ; 700]	390	0,29 %
nst	[3 ; 1000]	7	0,01 %
gap	[0 ; 360]	0	0,00 %
dmin	[0 ; 100]	0	0,00 %
rms	[0 ; 10]	0	0,00 %
sig	[0 ; 5000]	0	0,00 %
mag	[2 ; 9]	0	0,00 %

Tableau 3 : Détection des valeurs aberrantes.


```
mag : 0.08 % outliers
depth_km : 11.8 % outliers
nst : 5.83 % outliers
gap : 0.13 % outliers
dmin : 8.47 % outliers
rms : 0.32 % outliers
```

Figure 6 : Rapport des pourcentages de valeurs aberrantes.

3.2 Filtrage des valeurs aberrantes

Après la détection, un filtrage a été appliqué afin de conserver uniquement les observations respectant les intervalles physiques définis.

L'ensemble de ces règles a été implémenté dans une fonction dédiée (`remove_outliers()`), permettant d'automatiser le nettoyage.

Au terme de cette étape, moins de **0,3 %** des observations ont été supprimées, ce qui montre que le jeu de données initial présentait déjà une très bonne qualité.

4. Nettoyage des variables catégorielles

4.1 Filtrage selon le statut des événements

La variable **status** indique le niveau de validation de chaque événement sismique.

Status	Effectif	Pourcentage	Décision
reviewed	135 090	99,29 %	Conservé
automatic	970	0,71 %	Supprimé

Tableau 4 : Les modalités du variable statut

Les événements portant le statut **automatic** correspondent à des détections automatiques qui n'ont pas encore été validées par des experts. Afin d'améliorer la fiabilité du jeu de données, seules les observations **reviewed** ont été conservées.




Figure 7 : Distribution de la variable status

4.2 Filtrage selon le type d'événement

Le catalogue de l'USGS contient différents types d'événements géophysiques. Toutefois, ce projet porte exclusivement sur les séismes naturels.

Type	Effectif	Pourcentage	Décision
earthquake	134 896	99,14 %	Conservé
mining explosion	1 013	0,74 %	Supprimé
ice quake	108	0,08 %	Supprimé
autres types	<0,05 %	<0,05 %	Supprimé

Tableau 5 : les modalités de variable 'type'

Seuls les événements de type **earthquake** ont donc été conservés pour les analyses et la modélisation.




Figure 8 : Distribution des types d'événements avant filtrage.

5. Vérification finale du nettoyage

À l'issue des différentes opérations de nettoyage, une dernière vérification a été réalisée afin de confirmer la qualité du jeu de données obtenu.

Les traitements appliqués ont permis :

- d'éliminer toutes les valeurs manquantes des variables conservées ;
- de supprimer les observations aberrantes ne respectant pas les intervalles physiques retenus ;
- de conserver uniquement les événements sismiques naturels validés ;
- d'obtenir un jeu de données cohérent et adapté aux étapes suivantes de l'analyse exploratoire et de la modélisation.

6. Conclusion

Les opérations de nettoyage ont permis de transformer les données brutes issues de l'API de l'USGS en un jeu de données fiable, homogène et exploitable. Cette étape constitue une phase essentielle du projet, puisqu'elle garantit la qualité des informations utilisées pour les analyses spatiales, temporelles et pour l'entraînement des différents modèles d'intelligence artificielle développés dans la suite de ce travail.

Chapitre 4 : Analyse Exploratoire des Données (EDA)

1. Introduction

L’analyse exploratoire des données (Exploratory Data Analysis – EDA) constitue une étape essentielle permettant de comprendre la structure globale du jeu de données, la distribution des variables ainsi que les relations existantes entre elles avant toute phase de modélisation.

Elle permet notamment de détecter des tendances, d’identifier des comportements spécifiques des événements sismiques et d’orienter les choix méthodologiques pour les modèles prédictifs.

Dans ce travail, l’EDA est organisée selon quatre axes principaux :

Axe	Objectif	Méthodes
Univarié	Analyse d’une variable seule	Distributions, statistiques descriptives
Bivarié	Relation entre deux variables	Scatter plots, densités conditionnelles
Multivarié	Relations globales	Corrélations (Pearson, Spearman)
Spatial	Analyse géographique	Agrégations régionales

Tableau 6 : phases d'EDA

2 Analyse univariée

2.1 Évolution mensuelle du nombre de séismes

L’évolution du nombre de séismes a été étudiée sur la période 2021–2022 afin d’identifier des tendances temporelles.




Figure 9 : Nombre de séismes par mois (2021–2022)

Interprétation :

- Le nombre de séismes reste globalement stable sur la période.
- Les valeurs oscillent entre 1 500 et 2 400 événements mensuels.
- Aucun phénomène saisonnier clair n’est observé.
- Un pic ponctuel est visible en février 2021, probablement lié à une activité sismique exceptionnelle.

2.2 Évolution de la magnitude maximale




Figure 10 : Magnitude maximale mensuelle

Interprétation :

- En 2021, une baisse progressive de la magnitude maximale est observée.
- En 2022, la magnitude maximale reste constante à 8.0.
- Cela indique une période de forte activité initiale suivie d'une stabilisation.

2.3 Séismes majeurs et tsunamis




Figure 11 : Séismes ≥ 6.0 et occurrence de tsunamis

Interprétation :

- Le nombre de séismes majeurs augmente globalement entre 2021 et 2025.
- Entre 24% et 39% des séismes ≥ 6.0 génèrent un tsunami.
- Les données 2026 sont partielles.

2.4 Évolution de la magnitude maximale

Top 10 zones sismiques les plus actives




Figure 12 : Top 10 zones sismiques

Interprétation :

- L'Alaska domine largement l'activité sismique mondiale.
- Les zones les plus actives appartiennent à la ceinture de feu du Pacifique.
- Certaines zones isolées peuvent être liées à des activités anthropiques.

3. Analyse bivariable

3.1 Relation profondeur – magnitude




Figure 13 : Scatter plot profondeur vs magnitude

Interprétation :

- Les séismes de faible magnitude sont présents à toutes les profondeurs.
- Les séismes forts et majeurs apparaissent aussi bien en surface qu'en profondeur.
- Une forte densité est observée dans les zones superficielles (0–70 km).
- La magnitude maximale (8.0) apparaît dans différentes profondeurs.

3.2 Densité de profondeur selon la magnitude




Figure 14 : Densité de la profondeur par classe de magnitude

Interprétation :

- Pic très fort entre 0 et 10 km pour toutes les magnitudes.
- Décroissance rapide de la densité avec la profondeur.
- Les séismes profonds restent très rares.
- Les séismes forts montrent une légère présence dans les profondeurs intermédiaires.

4. Analyse spatiale

4.1 Top 15 régions sismiques




Figure 15 : Top 15 régions sismiques

Interprétation :

- L'Alaska concentre une part très importante de l'activité mondiale.
- Toutes les régions appartiennent à la ceinture de feu du Pacifique.
- La magnitude moyenne constante suggère un seuil de détection homogène.

5. Analyse multivariée

5.1 Corrélations (Pearson et Spearman)




Figure 16 : Matrices de corrélation

Deux types de corrélation ont été utilisés :

- **Pearson** : relation linéaire
- **Spearman** : relation monotone (plus robuste pour les données sismiques)

5.2 Corrélations fortes

Variables	Interprétation
sig ↔ nst	Très forte corrélation positive
gap ↔ nst	Forte relation inverse
rms ↔ gap	Relation modérée
dmin ↔ rms	Influence de la distance sur l'erreur

Tableau 7 : Corrélations fortes

5.3 Corrélations faibles

Variables	Interprétation
depth_km ↔ mag	Très faible relation
depth_km ↔ gap	Aucune relation
mag ↔ rms	Très faible relation
depth_km ↔ nst	Négligeable

Tableau 8 : Corrélations faibles

5.4 Synthèse multivariée

- Forte redondance entre sig, nst et gap.
- Depth et magnitude sont indépendants des autres variables.
- Possibilité de réduction de dimension pour la modélisation.

5.5 Synthèse globale de l'EDA

Domaine	Découverte	Impact
Temporel	Pas de saisonnalité	Modélisation basée sur tendance
Spatial	Alaska dominante	Poids important dans les modèles
Profondeur	Séismes majoritairement superficiels	Risque élevé en surface
Tsunami	Forte proportion liée aux séismes ≥ 6	Variable critique
Multivarié	Forte corrélation entre variables qualité	Réduction de dimension nécessaire

Tableau 10 : synthèse de EDA

Chapitre 5 : Préparation des données pour la modélisation

1. Introduction

Après les étapes de nettoyage et d'analyse exploratoire, les données ont été préparées afin de répondre aux exigences des modèles d'apprentissage développés dans ce projet. Chaque modèle poursuit un objectif différent et nécessite donc une préparation spécifique des données.

Modèle	Objectif	Type de données
Modèle 1	Classification de la magnitude	Données tabulaires
Modèle 2	Prévision hebdomadaire du nombre de séismes	Série temporelle

Tableau 11 : modèles développés

Les étapes de préparation comprennent notamment la création des variables cibles, les transformations logarithmiques, l'encodage des variables, la création de nouvelles caractéristiques, la sélection des variables pertinentes ainsi que le découpage des données en ensembles d'entraînement, de validation et de test.

2. Préparation des données pour le Modèle 1 : Classification de la magnitude

2.1 Création de la variable cible

L'objectif du premier modèle est de prédire la classe de magnitude d'un séisme. La variable continue **mag** a donc été transformée en une variable catégorielle composée de quatre niveaux de risque.

Classe	Intervalle de magnitude
Faible	[2 ; 4[
Modéré	[4 ; 5[
Fort	≥ 5.5

Tableau 12 : Classement du magnitude

Une nouvelle variable **mag_class_num_merged** est utilisée comme variable cible du modèle.




Figure 17 : Distribution des classes de magnitude

2.2 Analyse de l'équilibre des classes

Avant l'entraînement des modèles de classification, nous avons étudié la répartition des différentes classes afin d'évaluer un éventuel déséquilibre du jeu de données.

L'analyse a porté sur :

- la distribution des classes de magnitude ;
- la distribution des types de magnitude (magType) ;
- la répartition géographique des événements.

Le rapport de déséquilibre calcule le ratio entre la classe majoritaire et la classe minoritaire.

Selon ce ratio :

- $\text{ratio} < 10$: déséquilibre acceptable ;
- $\text{ratio} \geq 10$: utilisation de **class_weight='balanced'** durant l'entraînement.

Cette vérification permet d'éviter que le modèle privilégie systématiquement les classes les plus représentées.

2.3 Transformation logarithmique

Certaines variables numériques présentent une forte asymétrie (skewness) avec quelques valeurs extrêmement élevées.

Une transformation logarithmique de type **$\log_{1p}(x) = \log(1+x)$** a donc été appliquée afin de réduire cette asymétrie.

Variables concernées :

Variable originale	Variable transformée
depth_km	depth_km_log
nst	nst_log
dmin	dmin_log
sig	sig_log

Tableau 13 : les transformations logarithmiques

Cette transformation permet :

- de réduire l'influence des valeurs extrêmes ;
- d'obtenir des distributions plus proches d'une loi normale ;
- de faciliter l'apprentissage des modèles.

Les distributions ont été comparées avant et après transformation.




Figure 18 : Histogrammes avant/après transformation logarithmique

2.4 Détection du Data Leakage

Avant l'entraînement, une analyse des corrélations de Spearman entre les variables explicatives et la variable cible a été réalisée.

Les résultats montrent que certaines variables possèdent une corrélation extrêmement élevée avec la magnitude.

```

Top corrélations avec 'mag' (Spearman) :
-----
sig          : +0.992  *** Fort
sig_log      : +0.992  *** Fort
dmin_log     : +0.644  *** Fort
dmin         : +0.644  *** Fort
latitude     : -0.535  *** Fort
rms          : +0.464  *** Fort
longitude    : +0.457  *** Fort
nst          : +0.409  *** Fort
nst_log      : +0.409  *** Fort
gap          : -0.347  **  Modéré
depth_km     : +0.151  *   Faible
depth_km_log : +0.151  *   Faible
tsunami      : +0.082  *   Faible

```

Figure 19 ; Top corrélations avec la magnitude

Les variables **sig** et **sig_log** ont été supprimées car elles contiennent indirectement une information très proche de la variable cible.

Leur utilisation aurait introduit un phénomène de **data leakage**, conduisant à des performances artificiellement élevées sans réelle capacité de généralisation.

2.5 Préparation des variables explicatives:

Les principales opérations réalisées sont :

- suppression de la variable cible ;
- suppression des variables présentant un risque de data leakage ;
- imputation des valeurs numériques par la médiane ;

- imputation des variables catégorielles par la modalité la plus fréquente ;
- encodage One-Hot des variables catégorielles.

2.6 Découpage Train/Test

Le modèle de classification utilise un découpage aléatoire stratifié.

Ensemble	Pourcentage
Train	80 %
Test	20 %

Tableau 14 : Split du data

3. Préparation des données pour le Modèle 2 : Prévision temporelle

3.1 Construction de la série temporelle

Le second modèle prédit le nombre de séismes de la semaine suivante.

Les données événementielles ont donc été agrégées par semaine.

Chaque observation hebdomadaire contient notamment :

- nombre de séismes ;
- magnitude maximale ;
- magnitude moyenne ;
- profondeur moyenne ;
- nombre de tsunamis ;
- nombre de zones actives ;
- énergie sismique totale.

	date	nb_seismes	mag_max	mag_mean	mag_median	depth_mean	tsunami_sum	nb_zones	nb_seismes_clean	energy_sum
0	2015-01-05	197	5.6	4.482792	4.4	74.227010	5	167	197	2.560355e+09
1	2015-01-12	243	6.5	4.502881	4.4	88.835140	2	205	243	1.004695e+10
2	2015-01-19	237	5.7	4.515443	4.5	104.892907	3	197	237	3.612158e+09
3	2015-01-26	250	6.8	4.472120	4.4	88.609612	4	213	250	1.878276e+10
4	2015-02-02	275	6.3	4.523527	4.4	91.872175	7	223	275	1.136276e+10

Figure 20 : DataFrame hebdomadaire

3.2 Création des variables de retard (Lag Features)

Afin de modéliser la dépendance temporelle, plusieurs variables de retard ont été créées.

Pour le nombre de séismes :

- lag_1
- lag_2
- lag_3

- lag_4
- lag_8
- lag_12
- lag_52

Des retards ont également été calculés pour :

- energy_sum
- nb_zones

	lag_1	lag_2	lag_3	lag_4	lag_8	lag_12	lag_52	energy_lag_1	energy_lag_2	energy_lag_4	zones_lag_1	zones_lag_2
0	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
1	197.0	NaN	NaN	NaN	NaN	NaN	NaN	2.560355e+09	NaN	NaN	167.0	NaN
2	243.0	197.0	NaN	NaN	NaN	NaN	NaN	1.004695e+10	2.560355e+09	NaN	205.0	167.0
3	237.0	243.0	197.0	NaN	NaN	NaN	NaN	3.612158e+09	1.004695e+10	NaN	197.0	205.0
4	250.0	237.0	243.0	197.0	NaN	NaN	NaN	1.878276e+10	3.612158e+09	2.560355e+09	213.0	197.0
5	275.0	250.0	237.0	243.0	NaN	NaN	NaN	1.136276e+10	1.878276e+10	1.004695e+10	223.0	213.0
6	229.0	275.0	250.0	237.0	NaN	NaN	NaN	3.047816e+09	1.136276e+10	3.612158e+09	198.0	223.0
7	254.0	229.0	275.0	250.0	NaN	NaN	NaN	7.432200e+10	3.047816e+09	1.878276e+10	221.0	198.0
8	254.0	254.0	229.0	275.0	197.0	NaN	NaN	1.471462e+10	7.432200e+10	1.136276e+10	217.0	221.0
9	268.0	254.0	254.0	229.0	243.0	NaN	NaN	3.716643e+10	1.471462e+10	3.047816e+09	226.0	217.0

Figure 21 : Aperçu des variables lag

Ces variables permettent au modèle de tenir compte de l'historique récent de l'activité sismique.

3.3 Création de variables physiques

Plusieurs indicateurs ont été construits afin de mieux représenter l'activité sismique.

Variable	Description
energy_per_seisme	énergie moyenne par séisme
log_energy	énergie totale transformée en logarithme
mag_spread	dispersion des magnitudes
delta_seismes	évolution hebdomadaire
tsunami_ratio	proportion de séismes générant un tsunami

Tableau 15 : Les variables physiques

	date	energy_per_seisme	tsunami_ratio	mag_spread	delta_seismes	log_energy
589	2026-04-27	1.864349e+07	0.0	1.629966	-33.0	22.434740
590	2026-05-04	2.072397e+07	0.0	1.481792	-84.0	22.208094
591	2026-05-11	3.320545e+07	0.0	1.558111	2.0	22.688863
592	2026-05-18	1.079336e+08	0.0	2.081104	-51.0	23.596893
593	2026-05-25	1.590777e+08	0.0	1.831294	-78.0	23.339251

Figure 22 : Variables physiques

3.4 Encodage des variables cycliques

Même si l'EDA n'a pas montré de saisonnalité marquée, des variables cycliques ont été créées afin de représenter correctement les périodes de l'année.

Les semaines ont été encodées sous forme sinus/cosinus.

```
week_sin
week_cos
month_sin
month_cos
```

Cet encodage évite la discontinuité entre la dernière semaine d'une année et la première semaine de l'année suivante.

3.5 Sélection des variables

Après l'analyse des corrélations, des valeurs SHAP et des connaissances métier, les variables suivantes ont été retenues :

- nb_zones
- energy_per_seisme
- log_energy
- energy_lag_1
- energy_rolling_4
- mag_max
- mag_spread
- depth_mean
- lag_1
- lag_2
- lag_3
- rolling_mean_4
- rolling_mean_8
- rolling_mean_26
- rolling_std_8
- rolling_max_4
- zones_lag_1
- zones_lag_2

- week_sin

La variable cible est :

TARGET = nb_seismes




Figure 23 : Importance des variables (SHAP)

3.6 Normalisation des variables

Les modèles de réseaux de neurones étant sensibles aux différences d'échelle entre les variables, une normalisation par **StandardScaler** a été appliquée.

Cette étape permet :

- un apprentissage plus stable ;
- une convergence plus rapide ;
- une meilleure performance du modèle LSTM.

3.7 Découpage chronologique

Contrairement au modèle de classification, les données temporelles ne peuvent pas être mélangées aléatoirement.

Le découpage respecte donc l'ordre chronologique.

Ensemble	Proportion
Train	60 %
Validation	20 %
Test	20 %

Tableau 16: train/split

Chapitre 6 : Modélisation

1. Introduction

Ce chapitre présente les trois modèles développés pour l'analyse spatio-temporelle des événements sismiques. Chaque modèle répond à un objectif spécifique et utilise des algorithmes adaptés à la nature du problème.

Modèle	Objectif	Type d'algorithme
Modèle 1	Classification de la magnitude	Apprentissage supervisé (classification)
Modèle 2	Prévision du nombre de séismes	Apprentissage supervisé (régression temporelle)
Modèle 3	Prévision spatiale par zone	Clustering + Régression

Tableau 17 : Les modèles proposés

2.Modèle 1 : Classification de la magnitude

2.1 Objectif

Prédire la classe de magnitude d'un séisme à partir des caractéristiques mesurées (localisation, profondeur, qualité des mesures, etc.). La variable cible **mag_class** comporte quatre classes : **Faible, Modéré, strong**

2.2 Algorithmes testés

Nous avons comparé plusieurs algorithmes de classification supervisée :

Algorithme	Type	Avantages
Random Forest	Ensemble (bagging)	Robuste, gère les non-linéarités, importance des features
XGBoost	Ensemble (boosting)	Rapide, performant, gère le déséquilibre
Gradient Boosting	Ensemble (boosting)	Précision élevée mais plus lent
Decision Tree	Arbre unique	Interprétable mais risque d'overfitting
KNN	Distance	Simple, non paramétrique
Logistic Regression	Linéaire	Rapide, interprétable
SVM	Marge	Efficace en haute dimension

Tableau 18 : Les algorithmes testés

2.3 Entraînement et évaluation croisée

Chaque modèle a été évalué avec :

- Validation croisée à 5 folds (stratifiée)
- Métriques : Accuracy, F1-Macro, F1-Weighted
- Détection d'overfitting : Comparaison train vs validation

2.4 Résultats

Modèle	Accuracy	F1-Macro	F1-Weighted	CV F1	±	Overfit?	Temps
Random Forest	0.9970	0.9891	0.9970	0.9885	0.0021	● NON	15.0s
XGBoost	0.9972	0.9870	0.9972	0.9886	0.0021	● NON	7.5s
Gradient Boosting	0.9968	0.9853	0.9968	0.9874	0.0019	● NON	356.9s
Decision Tree	0.9758	0.6788	0.9686	0.9879	0.0022	● OUI	5.6s
KNN	0.9391	0.7861	0.9468	0.7944	0.0022	● NON	9.5s
Logistic Regression	0.9507	0.6783	0.9445	0.9384	0.0040	● OUI	4.9s
SVM	0.9882	0.9555	0.9883	0.9367	0.0047	● NON	213.3s

Figure 24 : Tableau comparatif des modèles (résultats)

2.5 Analyse des résultats

Meilleur modèle : Random Forest

🏆 MEILLEUR MODÈLE : Random Forest
F1-Macro : 0.9891
F1-Weighted: 0.997
Accuracy : 0.997
CV F1-Macro: 0.9885 ± 0.0021
Overfitting: ● NON

Pourquoi Random Forest ?

- Excellente précision (99.7 %)
- Très faible variance (écart-type CV = 0.0021)
- Pas d'overfitting
- Bon équilibre performance / temps de calcul
- Interprétabilité via l'importance des features

XGBoost est très proche en performance et plus rapide (7.5 s vs 15 s), mais Random Forest est légèrement plus stable.

2.6 Vérification de l'overfitting

Pour s'assurer qu'il n'y a pas d'overfitting, nous avons comparé les prédictions sur l'ensemble d'entraînement et sur l'ensemble de test.




Figure 25 : Diagramme de comparaison réel vs prédit (entraînement / test)

Observation : Les écarts entre les performances sur le train et sur le test, confirmant l'absence d'overfitting.

3.Modèle 2 : Prédiction temporelle (approche globale)

3.1 Objectif

Prédire le nombre de séismes pour la semaine suivante à partir de l'historique des 52 dernières semaines. Il s'agit d'un problème de régression sur série temporelle.

3.2 Algorithmes testés

Nous avons comparé des modèles classiques de régression et des modèles spécifiques aux séries temporelles.

Modèle	Type	Caractéristiques
XGBoost	Boosting	Gère les non-linéarités, rapide
Random Forest	Bagging	Robuste, bonne généralisation
LightGBM	Boosting	Optimisé pour les grandes données
SARIMA	Statistique	Modèle saisonnier (période 52 semaines)
ARIMA	Statistique	Modèle non saisonnier
Holt-Winters (ETS)	Lissage	Capture tendance et saisonnalité
Baseline naïf	Référence	Prédiction = valeur de la semaine précédente

Tableau 19 :Les modèles proposés pour TimeSeries

3.3 Résultats

Modèle	MAE	RMSE	R ²	MAPE%
XGBoost	28.6	41.5	0.7839	11.36
Random Forest	31.2	39.4	0.8061	11.73
LightGBM	34.6	49.8	0.6895	12.68
SARIMA(2,0,1)(1,0,0)[52]	58.5	91.7	-0.0519	20.39
ARIMA(2,0,1)	59.3	93.5	-0.0941	20.08
Holt-Winters (ETS)	63.1	97.0	-0.1778	21.27
Baseline naïf (lag_1)	64.1	91.9	-0.0584	19.91

Figure 26 : Tableau comparatif des modèles temporels

3.4 Analyse des résultats

Modèle retenu : XGBoost

Métrique	Valeur	Interprétation
MAE	28.6	En moyenne, l'erreur est de ± 29 séismes par semaine
R ²	0.78	Le modèle explique 78 % de la variance
MAPE	11.36 %	L'erreur relative moyenne est de 11 %

Tableau 20 : les métriques

Pourquoi XGBoost plutôt que Random Forest ?

Critère	XGBoost	Random Forest	Avantage
MAE	28.6	31.2	XGBoost
R ²	0.78	0.81	Random Forest
MAPE	11.36 %	11.73 %	XGBoost
Temps d'entraînement	Plus rapide	Plus lent	XGBoost

Tableau 21 : justification du modèle

Les deux modèles sont très proches. XGBoost a été retenu pour sa meilleure MAE et MAPE (erreur absolue et relative plus faibles), ainsi que sa rapidité d'exécution.

Comparaison avec les modèles statistiques :

- XGBoost réduit l'erreur (MAE) de plus de 50 % par rapport à SARIMA (28.6 vs 58.5).
- Les modèles ARIMA et SARIMA ont un R² négatif, ce qui signifie qu'ils sont moins performants qu'une prédiction constante.
- Le modèle naïf (prédiction = semaine précédente) est très mauvais.

3.5 Visualisation des prédictions




Figure 27 : Diagramme de comparaison valeurs réelles vs prédites (XGBoost)

Observations :

- Le modèle capture bien la tendance générale.
- Les pics d'activité (forts nombres de séismes) sont correctement identifiés mais parfois sous-estimés.
- Les périodes de calme sont bien modélisées.

4. Modèle 3 : Prévision spatiale (approche par zone)

4.1 Objectif

Le modèle 3 vise à affiner les prévisions du modèle 2 en les déclinant par zone géographique. Plutôt qu'une prédiction globale (« 250 séismes la semaine prochaine »), le modèle 3 prédit la répartition de ces séismes entre différentes zones (« Alaska : 120, Japon : 45, Chili : 30... »).

4.2 K-Means : Construction des zones spatiales

Pour regrouper les événements sismiques en zones cohérentes, nous avons appliqué l'algorithme K-Means sur les coordonnées géographiques (latitude, longitude).

Paramètres :

- Nombre de clusters : 10 (déterminé par la méthode du coude)
- Initialisation : k-means++
- Distance : euclidienne (coordonnées normalisées)

Distribution des séismes par zone :

```
zone
3.0  41886
1.0  21927
5.0  21550
7.0  16675
8.0  14934
2.0  14934
6.0  13385
9.0  12372
4.0   7966
0.0   7872
Name: count, dtype: int64
```

Figure 28 : Les 10 clusters

Exemple d'affectation :

latitude	longitude	zone
-3.2525	146.1942	3.0
64.6073	-17.6866	4.0
53.7520	-165.6360	4.0
81.6983	118.4063	7.0
-18.1824	-177.8246	5.0

4.3 Agrégation temporelle par zone

Après affectation des zones, nous avons agrégé les données par semaine et par zone.

	date	zone	nb_seismes
0	2015-01-05	0.0	6
1	2015-01-05	1.0	29
2	2015-01-05	2.0	8
3	2015-01-05	3.0	56
4	2015-01-05	4.0	25
5	2015-01-05	5.0	12
6	2015-01-05	6.0	9
7	2015-01-05	7.0	27
8	2015-01-05	8.0	15
9	2015-01-05	9.0	10
10	2015-01-12	0.0	7
11	2015-01-12	1.0	34
12	2015-01-12	2.0	15
13	2015-01-12	3.0	65
14	2015-01-12	4.0	21

Figure 29 : Aperçu de l'agrégation par zone

4.4 Création des features temporelles par zone

Pour chaque zone, nous avons reproduit les mêmes transformations que pour le modèle 2.

Feature	Description
lag_1, lag_2, lag_3, lag_4	Nombre de séismes passé dans la zone
rolling_mean_4, rolling_mean_8	Moyenne mobile (4 et 8 semaines)
rolling_std_4, rolling_std_8	Écart-type mobile
rolling_max_4	Maximum mobile

	date	zone	nb_seismes	lag_1	lag_2	lag_3	lag_4	rolling_mean_4	rolling_std_4	rolling_mean_8	rolling_std_8
0	2015-02-02	0.0	10	15.0	6.0	7.0	6.0	9.25	4.112988	10.000	3.545621
1	2015-02-09	0.0	11	10.0	15.0	6.0	7.0	6.75	1.500000	9.500	5.070926
2	2015-02-16	0.0	7	11.0	10.0	15.0	6.0	5.25	2.629956	6.250	3.327376
3	2015-02-23	0.0	6	7.0	11.0	10.0	15.0	17.75	14.930394	13.875	10.855380
4	2015-03-02	0.0	11	6.0	7.0	11.0	10.0	12.00	8.041559	11.250	7.629829

Figure 30: Aperçu des features temporelles par zone

4.5 Intégration du modèle 2 (prédiction globale)

L'architecture du modèle 3 est la suivante :




Figure 31 : Exemple de fonctionnement du modèle 3

Spécificité : La prédiction globale du modèle 2 est ajoutée comme feature d'entrée pour chaque modèle par zone. Ainsi, le modèle de chaque zone apprend à ajuster sa prédiction en fonction du niveau d'activité global attendu.

4.6 Résultats par zone

Chaque zone dispose de son propre modèle XGBoost entraîné sur son historique spécifique. Les performances varient selon le nombre de séismes dans la zone (plus de données = meilleure précision).

	zone	pred_seismes_next_week	latitude	longitude
0	3.0	31.465191	-3.778852	130.181982
1	7.0	26.034664	46.965972	150.517185
2	1.0	23.880671	20.892559	123.770189
3	5.0	21.913828	-22.997278	-177.169531
4	2.0	21.208666	-24.392466	-68.516140
5	8.0	18.099892	36.437097	48.534433
6	9.0	16.354296	-29.753557	154.454354
7	6.0	15.104727	11.923243	-81.553629
8	4.0	10.455237	54.891884	-117.849915
9	0.0	8.602367	-55.962440	-35.725944

Tableau 22 : Tableau des performances par zone

Apport du modèle 3 :

- Identifie quelles zones seront les plus actives.
- Permet une gestion de crise ciblée (ex. : préparer l'Alaska cette semaine).
- Détecte les zones émergentes (activité anormalement élevée pour cette zone).

5. Synthèse des performances

Modèle	Objectif	Meilleur algorithme	Performance clé
Modèle 1	Classification magnitude	Random Forest	F1-Macro = 0.989
Modèle 2	Prévision globale (nb séismes)	XGBoost	MAE = 28.6, R ² = 0.78
Modèle 3	Prévision spatiale (par zone)	K-Means + XGBoost	Répartition par 10 zones

Tableau 23 : Synthèse des performance

Chapitre 7 : Intégration des modèles dans un dashboard interactif en temps réel

1. Introduction

Après le développement, l'entraînement et l'évaluation des différents modèles d'intelligence artificielle, l'étape suivante consiste à les intégrer dans une application capable de fonctionner automatiquement avec des données réelles.

Pour répondre à cet objectif, chaque modèle a été encapsulé dans une fonction dynamique indépendante. Ces fonctions sont responsables de la récupération des données sismiques depuis l'API USGS, de leur prétraitement, de l'exécution des prédictions et de la génération des résultats au format JSON.

L'ensemble de ces fonctions est ensuite orchestré par un pipeline central qui permet d'actualiser automatiquement toutes les prédictions avant leur affichage dans un tableau de bord interactif. Cette architecture assure une mise à jour en temps réel des informations et facilite l'exploitation des modèles par les utilisateurs finaux.

2. Architecture générale du pipeline dynamique

L'application est organisée autour de quatre modules principaux.

1. Module de classification des séismes
2. Module de prévision globale
3. Module de prédiction par zones
4. Module d'orchestration du pipeline

Chaque module fonctionne indépendamment mais communique avec le dashboard via des fichiers JSON générés automatiquement.




Figure 32: Pipeline d'automatisation

3. Fonction dynamique de classification des séismes

Le premier module, implémenté dans **fetch_classification.py**, automatise complètement le processus de classification des séismes récents.

À chaque exécution, la fonction réalise les étapes suivantes :

- téléchargement des séismes enregistrés durant les dernières 24 heures depuis l'API USGS ;
- chargement automatique du meilleur modèle de classification disponible ;
- prétraitement identique à celui utilisé lors de l'entraînement du modèle (suppression des valeurs aberrantes, création des variables temporelles, transformation logarithmique, imputation des valeurs manquantes et encodage des variables catégorielles) ;
- génération de la prédiction de la classe de magnitude ;
- calcul des probabilités associées à chaque classe ;
- sauvegarde des résultats dans un fichier **output_classification.json**.

Le choix automatique du meilleur modèle permet au système d'utiliser directement la version la plus performante sans modifier le code de l'application.

Le fichier JSON généré est ensuite utilisé par le dashboard afin d'afficher en temps réel les derniers séismes, leur niveau de danger ainsi que le degré de confiance de la prédiction.

4. Fonction dynamique de prévision temporelle

Le second module, **fetch_timeseries.py**, est chargé de prévoir le nombre global de séismes attendus durant la semaine suivante.

À chaque lancement, la fonction :

- récupère les données des sept derniers jours ;
- met automatiquement à jour l'historique hebdomadaire ;
- calcule l'ensemble des variables temporelles (lags, rolling mean, énergie sismique, variables cycliques, etc.) ;
- charge automatiquement le meilleur modèle de prévision disponible ;
- produit une estimation centrale ainsi qu'un intervalle de confiance ;
- sauvegarde les résultats dans **output_forecast.json**.

Cette approche permet au dashboard de présenter une prévision actualisée sans nécessiter un nouvel entraînement à chaque exécution.

5. Fonction dynamique de prédiction des zones à risque

Le troisième module, **fetch_zones.py**, réalise la prédiction spatiale des séismes.

Son fonctionnement repose sur les étapes suivantes :

- téléchargement des séismes de la semaine écoulée ;
- attribution automatique de chaque événement à une zone géographique grâce au modèle K-Means ;
- mise à jour de l'historique des zones ;
- calcul des variables temporelles propres à chaque zone ;
- chargement du modèle spécifique correspondant à chaque zone ;
- estimation du nombre de séismes attendu pour chaque zone ;
- classification automatique des zones selon leur niveau de risque ;
- génération du fichier **output_zones.json**.

Cette architecture permet au dashboard d'afficher une carte mondiale indiquant les zones présentant les risques sismiques les plus élevés pour la semaine suivante.

6. Orchestration du pipeline

Le fichier **run_all.py** constitue le point d'entrée principal de l'application.

Son rôle est de coordonner l'ensemble des modules afin de produire automatiquement toutes les prédictions nécessaires au dashboard.

Le pipeline exécute successivement :

1. la classification des séismes récents ;
2. la prévision globale hebdomadaire ;
3. la prédiction des zones à risque.

Grâce à cette organisation, une simple exécution de **run_all.py** suffit pour actualiser l'ensemble des informations utilisées par le dashboard.

7. Alimentation du dashboard interactif

Les résultats produits par chaque fonction sont sauvegardés au format JSON.

Le frontend interroge directement ces fichiers afin d'afficher en temps réel :

- les derniers séismes détectés ;
- leur classe de magnitude ;
- les probabilités associées aux prédictions ;
- la prévision du nombre de séismes pour la semaine suivante ;
- les zones géographiques les plus exposées ;
- les indicateurs de fonctionnement du pipeline.

Cette séparation entre les modèles d'intelligence artificielle et l'interface graphique facilite la maintenance du système et permet une actualisation rapide des informations sans modifier le dashboard.

8. Résultat final : Dashboard interactif

Dans cette dernière section, présente une capture d'écran complète de ton tableau de bord.




Figure 33 : – Dashboard interactif de prévision sismique développé dans ce projet.

Le dashboard développé centralise l'ensemble des résultats produits par les différents modèles d'intelligence artificielle. Il fournit une visualisation en temps réel des séismes récents, des prévisions hebdomadaires, des zones à risque ainsi que des informations relatives au fonctionnement du pipeline MLOps. Cette interface constitue le point de contact entre les modèles développés et l'utilisateur final, permettant une consultation simple, rapide et interactive des prédictions générées par le système.

Concrètement, le tableau de bord s'articule autour de trois composantes principales :

- **Un diagramme linéaire (courbe)** , qui enregistre le nombre de séismes par semaine sur les 12 dernières semaines. À partir de cet historique, le modèle d'IA calcule et affiche directement sur le graphique une prédiction pour la semaine à venir (N+1), permettant à l'utilisateur d'anticiper les tendances (hausse ou baisse).
- **Un diagramme circulaire (camembert)** , qui propose une classification actuelle de chaque ligne sismique détectée. Il répartit les événements enregistrés selon leur niveau d'intensité (Faible, Modéré, Fort), offrant ainsi une photographie instantanée de la sévérité des secousses.
- **Une carte interactive (Leaflet)** , qui matérialise les zones à risque identifiées pour la semaine prochaine. Elle localise précisément les zones sismiques (ex : Zone 4, Zone 6, Zone 7) avec leurs coordonnées GPS, et permet d'accéder en un clic aux statistiques détaillées de chaque zone (nombre d'événements, classe de risque, etc.).

En complément de ces visualisations, le dashboard intègre plusieurs fonctionnalités techniques et ergonomiques :

- **Un rafraîchissement en temps réel** : l'interface se met à jour automatiquement pour refléter les dernières données disponibles, garantissant une information toujours à jour.
- **Un bouton d'actualisation manuelle** : l'utilisateur peut, à tout moment, cliquer sur ce bouton pour **déclencher le pipeline MLOps en quelques instants**. Ce dernier recharge l'intégralité des données, exécute les modèles de prédiction et met à jour l'ensemble des indicateurs et des cartes, assurant ainsi une fraîcheur totale des informations affichées.
- **Deux modes d'affichage** : le dashboard propose également un **mode sombre** et un **mode clair**, permettant à l'utilisateur d'adapter l'interface à ses préférences visuelles ou aux conditions de luminosité de son environnement de travail.

Ainsi, le dashboard ne se limite pas à une simple vitrine de données : il offre une expérience utilisateur fluide, réactive et personnalisable, où chaque graphique, chaque carte et chaque fonctionnalité répond à un besoin opérationnel précis, depuis le suivi temporel jusqu'à la géolocalisation des risques, en passant par le contrôle du pipeline de production.

Conclusion générale

Ce projet avait pour objectif de concevoir une plateforme intelligente de surveillance et de prévision de l'activité sismique en exploitant les techniques d'intelligence artificielle, les données ouvertes de l'USGS et les principes du MLOps. L'objectif principal était de développer un système capable de collecter automatiquement les données sismiques, de les analyser, de générer des prédictions fiables et de présenter les résultats au sein d'un tableau de bord interactif mis à jour en temps réel.

Dans un premier temps, un important travail de collecte et de prétraitement des données a été réalisé afin de garantir leur qualité et leur compatibilité avec les différents modèles développés. Les données ont été nettoyées, les valeurs manquantes traitées, les valeurs aberrantes supprimées et plusieurs variables pertinentes ont été construites pour améliorer les performances des modèles.

Par la suite, plusieurs modèles d'apprentissage automatique ont été développés pour répondre aux différents objectifs du projet. Un modèle de classification a permis d'estimer le niveau de magnitude des séismes récents, tandis qu'un modèle de séries temporelles a été conçu pour prévoir le nombre de séismes attendus au cours de la semaine suivante. En complément, une approche basée sur le clustering K-Means et des modèles de prédiction spécifiques à chaque zone a permis d'identifier les régions présentant un risque sismique plus élevé.

Afin d'assurer une exploitation efficace des modèles, une architecture MLOps a été mise en œuvre. Celle-ci automatise le versionnement, la comparaison des performances, la sélection du meilleur modèle ainsi que le réentraînement périodique lorsque cela est nécessaire. Cette approche améliore la robustesse du système et facilite son évolution dans le temps.

Enfin, l'ensemble des modèles a été intégré dans une architecture dynamique alimentant un dashboard interactif. Cette interface permet de visualiser en temps réel les séismes récents, les prévisions hebdomadaires, les zones à risque ainsi que les informations relatives au fonctionnement du pipeline, offrant ainsi un outil d'aide à la décision simple, intuitif et facilement exploitable.

Les résultats obtenus démontrent qu'il est possible de combiner les techniques d'intelligence artificielle, les données ouvertes et les pratiques MLOps pour développer une plateforme performante de surveillance sismique. Bien que la prévision des phénomènes naturels demeure un problème complexe et soumis à de nombreuses incertitudes, cette étude montre que les approches basées sur le Machine Learning peuvent constituer un support précieux pour l'analyse des risques et l'anticipation des événements.

Perspectives

Plusieurs pistes d'amélioration peuvent être envisagées afin d'enrichir cette plateforme. Il serait notamment intéressant d'intégrer des modèles de Deep Learning, tels que les réseaux LSTM ou Transformer, afin d'améliorer les performances des prévisions temporelles. L'exploitation de données complémentaires, telles que les mesures GPS, les données géologiques ou les observations satellitaires, pourrait également permettre d'augmenter la précision des modèles.

Par ailleurs, l'utilisation d'outils de déploiement et de supervision tels que Docker, Kubernetes ou MLflow offrirait une gestion encore plus avancée du cycle de vie des modèles. En définitive, ce projet met en évidence l'apport de l'intelligence artificielle dans le domaine de la surveillance sismique et ouvre la voie à des solutions intelligentes capables de contribuer à une meilleure compréhension et gestion des risques naturels.